



PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
Instituto de Ciências Exatas e de Informática

Modelagem Conceitual de Domínios para Aprendizado de Máquina via IA-Generativa dentro do conceito Human-in-the-loop*

Sophia Damasceno Satuf¹
Luis Enrique Zárate²

Resumo

Neste artigo, investiga-se o problema da dificuldade em mapear problemas complexos para construir bases de dados relevantes. O contexto desse problema envolve a necessidade de compreender todas as variáveis e faces que o compõem, destacando a importância de especialistas de domínio para validar as informações. A justificativa para abordar esse problema reside na existência de várias vertentes de mapeamento, sendo possível utilizar a inteligência artificial (IA) generativa para definir um método eficaz. O objetivo deste artigo é apresentar o algoritmo Sphere-M Remastered, projetado para capturar ontologias e construir bases de dados relevantes de forma inteligente, transformando informações em conhecimento. Os resultados apresentados demonstram a eficácia do algoritmo por meio de três casos de sucesso, validando sua aplicabilidade prática.

Palavras-chave: Base de Dados; Ontologia; IA Generativa; Knowledge Discovery in Databases.

Abstract

*Artigo apresentado ao Instituto de Ciências Exatas e Informática da Pontifícia Universidade Católica de Minas Gerais, campus Contagem, como pré-requisito parcial para obtenção do título de Bacharel em Sistemas de Informação.

¹Aluno(a) do Programa de Graduação em Ciência da Computação – 1427886@sga.pucminas.br.

²Professor(a) do Programa de Graduação em Ciência de Dados – zarate@pucminas.br.

This work investigates the problem of difficulties in mapping complex problems to construct relevant databases. The context of this problem involves understanding all the variables and facets that comprise it, highlighting the importance of domain experts to validate the information. The justification for addressing this problem lies in the existence of various mapping approaches, making it possible to utilize generative artificial intelligence (AI) to define an effective method. The objective of this work is to present the Sphere-M Remastered algorithm, designed to capture ontologies and construct relevant databases intelligently, transforming information into knowledge. The results presented demonstrate the algorithm's effectiveness through three successful cases, validating its practical applicability.

Keywords: Databases; Ontology; Generative AI; Knowledge Discovery in Databases;

1 INTRODUÇÃO

A área da Ciência de dados é uma área interdisciplinar que integra método científico, estatística, matemática e computação, visando dar soluções nos mais diversos contextos e domínios de problemas. A mineração de dados, uma subárea da ciência de dados, tem por objetivo construir modelos de aprendizado para inferir conhecimento científico a partir de fatos e evidências expressos nos dados. A subárea procura a descoberta de padrões objetivando conhecer aspectos dos fenômenos do mundo real, e para isso, pressupõe a identificação das principais variáveis que caracterizam o domínio de problema e a disponibilidade de dados representativos.

Em geral, qualquer projeto de mineração de dados busca conhecimento e informação aplicando tipicamente um processo de Descoberta de Conhecimento (Knowledge Discovery in Data Base – KDD) como proposto por (Fayyad; Piatetsky-Shapiro; Smyth, 1996). Com esse objetivo, diversas metodologias têm sido propostas (Martinez; Viles; G. Olaizola, 2021), embora todas converjam para as seis etapas essenciais sugeridas por Fayyad (seleção, pré-processamento, transformação, mineração de dados, validação e interpretação). Em relação à etapa de seleção, Fayyad ressalta a necessidade de entendimento do domínio da aplicação e da importância do conhecimento a priori acerca desse domínio.

O entendimento acerca de um domínio de problema deve começar pela aquisição de conhecimento acerca desse domínio. Segundo (Nonaka, 1991), o entendimento acerca de um domínio de problema pode vir de duas fontes de conhecimento: 1º) do conhecimento tácito, vindo da experiência do especialista de domínio, normalmente redundante, subjetivo e não formalizado, e 2º) do conhecimento explícito, sistematizado ou adquirido pelo estudo científico disponível acerca do domínio em questão. De acordo com o autor, ambos os conhecimentos não se separam e são mutuamente complementares. Porém, o conhecimento tácito é escasso e de difícil captura, mas se alcançado, poderia contribuir para melhorar o entendimento do domínio, o que pode resultar em projetos de ciência de dados na descoberta de padrões válidos, úteis e não óbvios.

Em relação ao conhecimento adquirido acerca de um domínio de problema, uma fonte

atual para aquisição desse conhecimento podem ser os Modelos de Linguagem de Grande Escala (LLMs). No entanto, esses modelos ainda enfrentam desafios de expertise (experiência profunda em uma área específica) quando aplicados, por exemplo, a contextos médicos complexos. Por exemplo, no contexto clínico, esses modelos não conseguem combinar conhecimento explícito, tipicamente utilizado para serem construídos (por exemplo, o material bibliográfico) e conhecimento tácito, baseado na experiência de um profissional médico. Esses modelos também podem trazer informações incorretas ou respostas não contextualizadas ao perfil dos pacientes, não podendo distinguir diferenças sutis entre perfis de pacientes. Em (Su et al., 2024), é proposta uma abordagem baseada em grafo para considerar tanto conhecimento explícito como tácito para lidar com a complexidade das consultas médicas. Ainda nessa direção, os trabalhos de (Chen, 2024), (Gu, 2024), (Bommasani, 2021) têm discutido um novo conceito de domain-specific foundation model para obtenção de modelos mais representativos dentro do contexto das LLM.

A ideia do envolvimento do especialista de domínio (quem é uma fonte valiosa de conhecimento tácito relevante) para entendimento de um domínio de problema não é uma recomendação atual, porém, muitas vezes é negligenciada. Em (Guyon et al., 2019), foi realizada uma análise das estratégias aplicadas pelos participantes durante desafios de AutoML. Os autores identificaram que a etapa do pré-processamento não foi alvo dos participantes, e que os participantes melhor posicionados no ranking não aplicaram uma etapa de seleção de atributos, e que 66% dos participantes ignoraram atributos irrelevantes. Atualmente, a busca por aprimorar a precisão dos modelos baseados em LLM tem aumentado o interesse na modelagem de domínios expressos por meio de grafos de conhecimento específicos de domínio, que correspondem a representações semânticas, ou de ontologias, acerca de um domínio. Recentemente, (Yuan et al., 2020) propôs a construção de grafos de conhecimento com mínima supervisão humana, e (Brady et al., 2020) apresenta um guia para pesquisadores da saúde pública interessados em construir modelos conceituais.

Dentro da área da ciência de dados, ainda não existe um método para incorporação do conhecimento prévio acerca do domínio de problema, ainda na fase inicial de um processo de descoberta de conhecimento. O especialista de domínio, muitas vezes, é uma entidade escassa, o que impõe restrições ao entendimento do domínio e, portanto, à construção de modelos representativos. Considerando o pressuposto que o entendimento acerca do domínio de problema é uma etapa essencial que pode auxiliar numa etapa de seleção conceitual de atributos, sobre o qual será aplicado um processo de descoberta de conhecimento e de geração de informação relevantes, neste trabalho é proposto um método denominado CAPTO2 para captura do conhecimento acerca do domínio, a partir de conhecimento extraído por modelos de IA-Generativa. É proposto um algoritmo pseudo-automático, que demanda intervenção humana, dentro do conceito human-in-the-loop (HITL) para construção de modelos conceituais para representação de domínios de problemas (Wu et al., 2022). Por meio do uso de HITL, pretende-se aumentar a representatividade do modelo, aumentar a confiabilidade transparência e explicabilidade.

Este artigo está organizado em três seções. Na segunda seção, é apresentado o método

CAPTO2 para captura de ontologia, elucidando as contribuições utilizadas em sua elaboração e explicando seu funcionamento por duas abordagens: uma de alto nível e outra algorítmica. Na proposta, também são apresentadas métricas para avaliar o processo desejado, seguidas de um exemplo de aplicação. Por fim, são apresentadas as contribuições e as conclusões deste trabalho.

2 TRABALHOS RELACIONADOS

Em (Budd; Robinson; Kainz, 2021) estudam a combinação do Aprendizado Ativo (AL) com auxílio do conceito Human-in-the-Loop para construção de modelos de aprendizado profundo na análise de imagens médicas. Os autores enfatizam a importância da intervenção humana em domínios críticos como a medicina. O trabalho explora como o AL pode otimizar a seleção de dados para anotação, a interação com as saídas do modelo para refinar previsões, e as considerações práticas para a implantação dessas tecnologias. O objetivo é alcançar modelos de alto desempenho com menor esforço de anotação, crucial em aplicações médicas.

(Wu et al., 2022), os autores realizam uma revisão acerca do conceito Human-in-the-Loop (HITL) aplicada na área de aprendizado de máquina (AM). Os autores classificam os trabalhos em três categorias principais: 1) Para melhoria do modelo via processamento de dados; 2) Para melhoria durante o processo de treinamento, com caráter intervencionista; e 3) Para melhoria do projeto de construção de sistemas HITL. O artigo destaca que o HITL visa treinar modelos precisos com custo mínimo, integrando o conhecimento humano, que muitas vezes supera o conhecimento de domínio aprendido pela máquina. São também discutidos os desafios e as oportunidades futuras para projetar soluções HITL mais eficazes.

(Wang; Guo; Chen, 2022) avalia como o aprendizado de máquina com intervenção humana pode solucionar desafios do AM, como dados de baixa qualidade ou insuficientes, e a necessidade de transparência. O trabalho propõe um framework denominado "Human4ML", que organiza estudos de HITL nas fases de preparação de dados guiada por humanos, seleção de características, aprendizado de modelo assistido por humanos e avaliação e explicação iterativa de modelos. O objetivo é construir um modelo de AM mais eficaz centrado no ser humano. (Memarian; Doleck, 2024) analisa as implicações do conceito HITL a partir de uma perspectiva de Entity-Relationship (ER) mais formal e aponta as diversas possibilidades de localizar humanos no circuito com a IA, como o próprio sistema de aprendizado e o domínio de interesse.

Choi e Jung (2025) apresentam uma revisão focada na construção automatizada de Grafos de Conhecimento (KGs), cobrindo publicações recentes, principalmente após 2022. O artigo aborda as três dimensões centrais da construção de KGs: Extração (incluindo pré-processamento de dados e extração multimodal), Paradigma de Aprendizagem (refinamento de embeddings, GNNs, Transformers, LLMs) e Metodologia de Avaliação (métricas intrínsecas e extrínsecas, interpretabilidade). O estudo enfatiza a crescente integração de LLMs com KGs

para gerenciar "alucinações" e a contínua evolução das técnicas em cada fase do desenvolvimento de KGs.

Outro método bem conhecido e eficaz é a extração de grafos de conhecimento específicos de domínio, particularmente em áreas biomédicas.

Grafos de conhecimento biomédico já são comumente utilizados para tomada de decisões nas áreas de biomedicina e saúde, incorporando conhecimento de domínio e aprimorando ações de saúde (Bai et al., 2016). Em (Yuan et al., 2020), os autores apresentam uma metodologia para construção de grafos de conhecimento com supervisão mínima, baseada em contextos biomédicos não estruturados e específicos de domínio. O trabalho abrange reconhecimento de entidades, incorporação não supervisionada de entidades e relações, geração de relações latentes por meio de agrupamento, refinamento de relações e atribuição de relações a agrupamentos de rótulos.

Este trabalho propõe um método denominado CAPTO2, responsável por guiar a tarefa de identificação e organização dos elementos (entidades ou conceitos) do domínio e descrever relações ontológicas básicas entre eles. O resultado do método é um modelo composto por entidades e relações básicas como *é-um* (is-a), *é-parte-de* (is-part-of), obtidas por meio do estudo ontológico do domínio. O método CAPTO2 pretende atuar um passo antes de um típico processo de descoberta de conhecimento a partir de dados (Knowledge discovery in database - KDD), oferecendo um modelo para guiar a seleção conceitual de características, obtendo modelos de aprendizado de máquina mais representativos.

3 BACKGROUND

3.1 Conceitualização de domínios

Ao modelar conceitualmente um domínio, é necessária a identificação de entidades e relacionamentos, ou ligações, que serão incorporadas no modelo. Nesse caso, é possível usufruir da tarefa de construção de ontologias para realizar essa tarefa.

Nesse contexto, ontologia é entendida como um artefato computacional que representa formalmente o conhecimento de um domínio específico, explicitando seus elementos, atributos, relações e restrições, definindo assim o vocabulário utilizado para descrever tal domínio em uma determinada linguagem. Th. R. Gruber forneceu uma das definições mais populares do termo ontologia, ao estabelecer que uma ontologia é uma especificação explícita compartilhada de uma conceitualização formal acerca de um domínio.

A definição de Gruber utiliza a ideia de conceitualização apresentada por Nilsson e Genesereth (Gruber, 1993). Segundo esses autores, a conceitualização pode ser dada de forma explícita ou implícita, ou seja, mesmo quando uma conceitualização não é explicitamente denotada, ela pode existir implicitamente na lógica de trabalho de uma solução de problema. Enquanto as conceitualizações implícitas não têm como propósito definir os elementos e rela-

ções do universo do discurso (domínio de problema), as explícitas exigem essa definição. Essa exigência traz dificuldades, devido às diversas formas de alcançar a conceitualização desejada. Os autores também afirmam que pode existir mais de uma conceitualização sobre o mesmo domínio, evidenciando o caráter subjetivo desse tipo de tarefa. Também é dito, pelos autores, que a tarefa de conceitualização é uma "invenção", existindo um comprometimento ontológico, de modo que uma conceitualização é sempre aceita se for útil para um determinado propósito. A área de aprendizado de máquina se beneficiaria se uma modelagem conceitualizada, de aproximação do mundo real, pudesse ser realizada previamente à construção de um modelo computacional de aprendizado. Um processo de seleção conceitual de variáveis, guiado por um modelo de conceitualização, poderia proporcionar modelos mais assertivos e representativos ao domínio de problema.

Esse comprometimento ontológico citado anteriormente, não pode ser ignorado, se o objetivo é a construção de modelos de aprendizado adequadamente fundamentados, já que a existência de conceitos não lógicos pode ser necessária em alguns domínios se eles tiverem importância para a aplicação desejada (Gruber, 1993). No entanto, essa liberdade conceitual pode ser vista como um obstáculo para o especialista que deseja investigar um universo de discurso (domínio) escolhendo entidades pertinentes para sua conceitualização. Assim, algumas questões surgem: Quais critérios devem ser utilizados durante essa modelagem conceitualizada? Quais etapas devem ser seguidas na identificação dos elementos e relações do domínio? Neste trabalho, estas são algumas das questões que se referem à tarefa de captura de ontologia para a modelagem conceitual de domínios.

M. Uschold e M. King definiram uma Metodologia Esquelética para Construção de Ontologias que frequentemente tem sido adaptada e incorporada em abordagens modernas (Jain; Sharma, 2016). Na primeira fase do método, é proposta a tarefa de captura de ontologia, que consiste em encontrar os conceitos-chave e as relações existentes no domínio. O resultado dessa atividade deve conter entidades (conceitos) e suas relações relevantes, identificados e organizados. Geralmente, essa tarefa é realizada por um especialista de domínio, que pode ser representado por uma fonte humana de conhecimento com auxílio de alguma ferramenta. A proposta deste trabalho é fornecer um método para o estudo ontológico de domínios, aplicável no processo de captura de ontologia, realizado por um especialista humano, uma vez que essa tarefa ainda não possui procedimentos ou métodos que orientem sua subjetividade por meio de regras claras. Para este trabalho, é proposto um algoritmo pseudo-automático, com intervenção humana, responsável pela decisão da inclusão ou não dos conceitos. Como base de conhecimento serão utilizados modelos de IA-Generativa, para modelar conceitualmente domínios de problemas.

3.2 Contribuições filosóficas para adquirir conhecimento

Para elaborar o método CAPTO2, foram extraídos alguns fundamentos filosóficos de teorias consideradas importantes para o processo de investigação da realidade. Esses fundamentos sugeriram critérios para encontrar e filtrar elementos de um domínio.

- **Variação e Especificação:** Baseado na ideia de Parmênides sobre o "mutável", esse fundamento sugere que uma entidade não pode se opor a si mesma, o que permite a variabilidade de sua forma e atributos. O método busca elementos mais específicos, definidos estritamente por suas características aparentes, sem a possibilidade de incluir outras variações. Isso justifica o mecanismo de especificação de elementos no método proposto.
- **Essência e Generalização:** A partir da ideia socrática de ir da "aparência para a essência", busca-se a noção essencial ou genérica de um elemento. Para obter um conceito verdadeiro, é necessário analisar vários indivíduos da mesma espécie para identificar sua "essência imutável", que pode definir o conceito de forma objetiva, sem lidar com as particularidades de cada instância. Esse fundamento sustenta a presença de um mecanismo de generalização de elementos no método.
- **Parte e Todo:** Inspirado no método de Descartes de dividir o conhecimento em partes menores para entendê-las individualmente e depois reuni-las de forma organizada, esse fundamento aborda a situação em que uma entidade pode ser parte de outra, ou, inversamente, pode ser vista como um grupo ou conjunto de outras entidades.
- **Regra Guia:** Uma restrição importante é extraída da teoria empírica de Locke, que afirma que as ideias são construídas a partir de experiências prévias e não são concebidas sem um referencial verdadeiro. Essa restrição, chamada de "Regra-Guia", exige verificar se um elemento gerado é viável, ou seja, se o domínio escolhido aceita sua existência. A regra é usada para limitar a geração de entidades, negando conceitos inviáveis.

Esses fundamentos são aplicados no método CAPTO2 através da Análise Ontológica Fundamental (AOF):

- **Especificação:** Se um elemento pode variar em características, cada variação corresponde a um elemento mais específico, resultando em relações "is-a-variation-of".
- **Generalização:** A abstração de algumas características de um elemento pode gerar um novo elemento mais genérico, resultando em relações "is-a".
- **Composição (Parte-Todo):** A separação de um elemento em seus componentes ou características cria novos elementos, gerando relações como "is-an-attribute-of", "is-a-component-of", "is-an-element-of" ou "is-part-of".
- **Agregação (Todo-Parte):** Se um grupo de elementos pode ser considerado um componente ou característica, definindo um conjunto consistente, ele representará um novo elemento, resultando em relações como "is-composed-by" ou "is-characterized-by".

3.3 Captura: Fundamentação e Proposições

O método proposto neste trabalho, chamado CAPTO2, visa guiar a tarefa de identificar e organizar os elementos de um domínio e descrever as relações ontológicas básicas entre eles. Ele foi criado para tornar o processo de conceitualização mais objetivo e auxiliar o cientista de dados nas etapas iniciais da criação de uma ontologia ou modelo conceitual. O resultado do método é um modelo composto por entidades e relações fundamentais como "é-um"(is-a), "é-parte-de"(is-part-of), obtidas através do estudo ontológico do domínio. O método pretende atuar um passo antes, oferecendo uma forma de criar um modelo conceitual simples que pode ser usado para capturar a ontologia e encorajar profissionais a iniciar a construção da ontologia investigando cuidadosamente o domínio. O modelo conceitual serviria para inserir uma nova etapa inicial do fluxo pipeline num processo de descoberta de conhecimento para obtenção de modelos mais representativos do domínio de problema considerado.

A seguir, são apresentadas as contribuições filosóficas que fundamentam o método, sua abordagem de alto nível e algorítmica, as métricas propostas para avaliar o processo e um exemplo didático de sua aplicação.

4 MÉTODO CAPTO2

O método CAPTO2 utiliza a técnica **Middle-out** para a análise do domínio, uma abordagem também utilizada em outros métodos de construção de ontologias. Essa técnica consiste em iniciar com a enumeração dos elementos iniciais importantes do domínio e, em seguida, mover-se tanto para o nível mais genérico quanto para o mais específico da estrutura ontológica, utilizando especificações e generalizações. O método Middle-out é considerado a opção mais equilibrada em comparação com as técnicas Top-down e Bottom-up.

Para definir uma condição de parada para o processo, o CAPTO2 se baseia na definição de conjuntos-chave:

- **CEILING:** Contém os elementos mais gerais que definem o assunto abordado no domínio.
- **FLOOR:** Inclui todas as entidades e elementos que se deseja que pertençam ao domínio.
- **RELEVANT ELEMENTS:** Composto por elementos que definem o foco das relações desejadas entre os conjuntos CEILING e FLOOR.
- **DOMAIN ELEMENTS:** O conjunto de trabalho inicial, que é a união dos três conjuntos-chave (CEILING, FLOOR, RELEVANT ELEMENTS).

O processo do método consiste em: 1. Definir os conjuntos-chave. 2. Juntar os conjuntos-chave para formar o conjunto DOMAIN ELEMENTS. 3. Submeter o conjunto DOMAIN ELEMENTS à AOF, gerando novas relações e, se necessário, novos elementos. 4. Verifi-

car se todos os elementos do DOMAIN ELEMENTS estão conectados aos conjuntos CEILING e FLOOR. 5. Retornar à etapa 3 se houver algum elemento não conectado aos conjuntos CEILING e FLOOR.

Uma conexão entre um elemento e os conjuntos CEILING e FLOOR só existe se houver um caminho que ligue o elemento a um elemento de cada um desses conjuntos. O método propõe uma analogia com uma esfera, onde o conjunto CEILING é o centro e o conjunto FLOOR é a superfície. A ontologia está bem representada quando esses dois conjuntos estão conectados pelos elementos do domínio, como a superfície de uma esfera se relaciona com o seu centro.

4.1 Abordagem Algorítmica do Método CAPTO2

A seguir, é apresentado o algoritmo CAPTO2, uma adaptação que incorpora a utilização de IA Generativa. O objetivo é formalizar a aplicação do método e permitir a utilização de métricas propostas para avaliar o processo. O algoritmo utiliza conjuntos para representar os elementos do domínio e suas relações.

O algoritmo proposto, apresentado a seguir, é uma extensão do método original de 2012 e inclui uma intervenção humana para validar as relações propostas pela IA Generativa. O algoritmo itera até que todos os elementos do domínio estejam conectados ao "teto"(C) e ao "pisso"(F).

Algorithm 1 Método Sphere Remastered

```
1:  $C \leftarrow$  entrada do usuário;  
2:  $F \leftarrow$  entrada do usuário;  
3:  $R \leftarrow$  entrada do usuário;  
4:  $E \leftarrow C \cup F \cup R$ ;  
5:  $G \leftarrow E$ ;  
6:  $L \leftarrow \emptyset$ ;  
7:  $A \leftarrow \emptyset$ ;  
8: for all  $c \in C$  do  
9:   Marque  $c$  como LinkedToCeiling;  
10: end for  
11: for all  $f \in F$  do  
12:   Marque  $f$  como LinkedToFloor;  
13: end for  
14: loop  
15:   loop  
16:     // Envie todos os elementos do conjunto  $E$  para a IA e peça para ela buscar relações:  
17:     buscaRelações( $E$ ,  $G$ );  
18:      $E \leftarrow E \cup G$ ; // Conjunto  $E$  recebe os elementos de  $G$  da iteração anterior  
19:      $G \leftarrow \text{temp}G$ ; // Conjunto  $G$  recebe os elementos gerados na iteração atual  
20:     Aplique FOA e construa árvores semânticas com as respostas da IA  $\forall l \in L$ ;  
21:     Se um elemento estiver relacionado a outro marcado como linkedToCeiling, marque-o  
       e propague a marca para seus adjacentes;  
22:     Se um elemento estiver relacionado a outro marcado como linkedToFloor, marque-o e  
       propague a marca para seus adjacentes;  
23:   end loop até que (não haja mais nada para relacionar ou gerar com os elementos de  $E$ )  
24: end loop até que ( $e$  é linkedToCeiling e linkedToFloor,  $\forall e \in E$ ) = 0
```

Algorithm 2 Função buscaRelações

buscaRelaçõesE, G

```
1: if  $G \neq \emptyset$  then
2:    $\text{tempG} \leftarrow \emptyset$ ;
3:    $GE = \{(gi, ei) \mid gi \in G; ei \in E, (gi, ei) \in G \times E, (gi \neq ei), (gi, ei) \in GE \rightarrow (ei, gi) \notin GE\}$ ;

4:   for all  $(gi, ei) \in GE$  do
5:      $LEG \leftarrow \emptyset$ ;
6:     Enviar prompt à IA = "Determine se há uma relação entre os elementos gi e ei. Se
       houver, descreva a relação."
7:      $LEG \leftarrow$  Lista de entes gerados pela IA com human-in-loop;
8:     if houver relação, por intervenção humana then
9:        $L \leftarrow (gi, ei, LEG)$ ;
10:      for all  $(gi, ei, LEG)$  do
11:        for all  $legi \in LEG$  do
12:           $\text{tempG} \leftarrow legi$ ;
13:           $A \leftarrow (ei, legi)$  e  $(legi, gi)$ ;
14:        end for
15:      end for
16:    end if
17:  end for
18: end if
```

4.2 Métricas

O método CAPTO2 oferece métricas para avaliar o processo de conceitualização. Elas podem ser usadas para quantificar e qualificar o caminho percorrido para obter um modelo final.

- **Número de Iterações:** Representa quantos passos foram dados no processo. Um número alto de iterações pode indicar que os conjuntos iniciais são difíceis de relacionar.
- **Raio da Esfera:** O número de iterações necessárias para alcançar o "estado conectado" da esfera, ou seja, quando todos os elementos estão ligados aos conjuntos CEILING e FLOOR. Um raio maior indica que os elementos não estão diretamente relacionados, exigindo a geração de muitos outros elementos através de mais iterações.
- **Número de Elementos na Esfera:** A cardinalidade do conjunto E (*DOMAIN ELEMENTS*) em qualquer iteração.
- **Densidade:** A razão entre o número de elementos conectados (ligados a CEILING e FLOOR) e o número total de elementos na esfera. A fórmula é:

$$Densidade = \frac{N_{\text{numero de elementos conectados}}}{N_{\text{numero de elementos na esfera}}}$$

Uma densidade de 1.0 significa que todos os elementos estão conectados, indicando que o processo pode ser interrompido.

- **Eficiência da Iteração:** A razão entre o número de relações obtidas (cardinalidade do conjunto L) e o número máximo possível de relações. O número máximo de combinações (MAX) é dado pela fórmula:

$$MAX = \frac{|E| \cdot (|E| - 1)}{2}$$

A fórmula para a eficiência é:

$$Eficiencia da Iterao = \frac{|L|}{MAX}$$

- **Produtividade da Esfera:** Se o estado conectado for alcançado, a produtividade é a razão entre o número de elementos na esfera e o raio da esfera.

$$Produtividade da Esfera = \frac{N_{\text{numero de elementos na esfera}}}{Raio da esfera}$$

Essa métrica representa a taxa de geração de elementos em relação ao número de iterações necessárias para conectar a esfera. É útil para avaliar um processo em andamento ou comparar processos com os mesmos conjuntos iniciais.

4.3 Exemplo ilustrativo

Para ilustrar o uso do método, é proposto um problema de extração de conhecimento a partir de um texto, onde um usuário humano atua como especialista de domínio.

Problema: Criar um modelo sobre o assunto "Telefone" com base no seguinte texto:

- Texto: "O telefone é um dispositivo de telecomunicações que é usado para transmitir e receber som (mais comumente fala). A maioria dos telefones opera através da transmissão de sinais elétricos em uma rede telefônica complexa que permite que quase qualquer usuário de telefone se comunique com quase qualquer outro."

Definições iniciais:

- O texto é segmentado em termos importantes: *Telefone, Dispositivo de Telecomunicações, Transmitir Som, Receber Som, Transmissão de Sinais Elétricos, Rede Telefônica, Usuário de Telefone, Comunicar.*

- O conjunto C (CEILING) é o assunto do texto: ' $C = \{Telephone\}$ '.
- O conjunto F (FLOOR) são os elementos extraídos do texto (neste exemplo, foi usado o conjunto E para isso, mas no algoritmo original E é a união de C , F e R).
- O conjunto R (RELEVANT ELEMENTS) são os termos que representam os problemas definidos: *Telephone Working*, *Telephone Utilization*.

Análise com a AOF: Na primeira iteração, a IA Generativa é usada para identificar relações entre os elementos iniciais do domínio, e um especialista valida essas relações. As relações resultantes, justificadas pela AOF, são:

- 'Telefone' **is-a** 'Dispositivo de Telecomunicações'. (Fundamento II)
- 'Transmitir Som' **is-part-of** 'Telephone Utilization'. (Fundamento III)
- 'Receber Som' **is-part-of** 'Telephone Utilization'. (Fundamento III)
- 'Transmissão de Sinais Elétricos' **is-part-of** 'Telephone Working'. (Fundamento III)
- 'Usuário de Telefone' **is-part-of** 'Telephone Utilization'. (Fundamento III)
- 'Comunicar' **is-a** 'Telephone Utilization'. (Fundamento II)
- 'Telephone Working' **is-part-of** 'Telephone'. (Fundamento III)
- 'Telephone Utilization' **is-part-of** 'Telephone'. (Fundamento III)

Métricas da primeira iteração: - Número de iterações: 1. - Número de elementos: 10. - Densidade: $9 \div 10 = 0.9$. - Eficiência da iteração: $8 \div 45 = 0.177$. - Produtividade: - (não aplicável pois a esfera não está totalmente conectada).

Um elemento, 'Rede Telefônica', ainda não foi relacionado, então a análise continua. Uma nova relação é encontrada: 'Telefone' **is-part-of** 'Rede Telefônica'.

Com essa nova relação, todos os elementos estão marcados como *linkedToCeiling* e *linkedToFloor*, o que significa que foi obtida uma esfera sólida. O processo pode ser interrompido, mas as métricas podem ser reavaliadas: - Número de iterações: 1. - Raio da Esfera: 1. - Número de elementos: 10. - Densidade: $10 \div 10 = 1.0$. - Eficiência da Iteração: $9 \div 45 = 0.2$. - Produtividade: $10 \div 1 = 10$.

Se uma segunda iteração for realizada para melhorar a eficiência, o raio da esfera mudaria. Supondo que a relação "'Transmissão de Sinais Elétricos' **is-a** 'Transmissão'" seja encontrada, um novo elemento 'Transmissão' é gerado. As métricas para a segunda iteração seriam: - Número de iterações: 2. - Raio da Esfera: 1. - Número de elementos: 11. - Densidade: $11 \div 11 = 1.0$. - Eficiência da Iteração: $10 \div 55 = 0.181$. - Produtividade: $11 \div 2 = 5.5$.

Neste caso, a eficiência e a produtividade diminuiriam, sugerindo que o novo elemento não foi útil para melhorar o modelo e poderia ser descartado.

5 RESULTADOS EXPERIMENTAIS

Este capítulo tem como objetivo apresentar e discutir os resultados obtidos com a aplicação do método CAPTO2 Remastered, que incorpora a IA Generativa no processo de captura de ontologias.

5.1 Exemplo de Iteração 1

Os conjuntos iniciais para a simulação são definidos como:

- C (Ceiling): $\{Professor\}$
- F (Floor): $\{Conhecimento\}$
- R (Relevant Elements): $\{Aprendizagem, Saladeaula, Aluno\}$

Conjuntos após a Inicialização (Linhas 4-7):

- $E = C \cup F \cup R: \{Professor, Conhecimento, Aprendizagem, Saladeaula, Aluno\}$
- $G \leftarrow E: \{Professor, Conhecimento, Aprendizagem, Saladeaula, Aluno\}$
- $L \leftarrow \emptyset$ (Lista de Relações)
- $A \leftarrow \emptyset$ (Arestas/Relações de Entes Gerados)

Marcas Iniciais (Linhas 8-13):

- $Professor$ é marcado como `LinkedToCeiling`.
- $Conhecimento$ é marcado como `LinkedToFloor`.

5.1.1 Iteração 1

Execução de `buscaRelações(E, G)`

Na Iteração 1, pares de elementos de E (o conjunto inicial) são enviados para a IA. Assume-se que o *Human-in-the-loop* (HITL) gera quatro novos entes (leg_1 a leg_4) a partir de 4 relações relevantes encontradas, atualizando L e $tempG$.

Tabela 1 – Resultados da função buscaRelações na Iteração 1 (Exemplos)

Par (g_i, e_i)	Relação Encontrada	Novos Entes Gerados (leg_i)
(Professor, Conhecimento)	Transmissão	$leg_1 = Transmitir$
(Professor, Aprendizagem)	Ação	$leg_2 = Ensinar$
(Conhecimento, Aluno)	Propriedade	$leg_3 = Adquirido$
(Professor, Sala de aula)	Localização	$leg_4 = Ambiente$

Estado Final dos Conjuntos (Iteração 1):

Tabela 2 – Estado Final dos Conjuntos (Iteração 1)

Conjunto	Conteúdo	Cardinalidade
E	$\{Prof, Conh, Apren, Saladeaula, Aluno\}$	$ E = 5$
G	$\{Transmitir, Ensinar, Adquirido, Ambiente\}$	$ G = 4$
L	$\{(P, C, \{T\}), (P, A, \{E\}), \dots\}$	$ L = 4$
A	$\{(Conh, T), (T, Prof), \dots\}$	$ A = 8$

Tabela 3 – Estado de Marcas Propagadas (Iteração 1)

Elemento	Marcas (C=Ceiling, F=Floor)
<i>Professor</i>	(C)
<i>Conhecimento</i>	(C, F)
<i>Aprendizagem</i>	(C)
<i>Saladeaula</i>	(C)
<i>Aluno</i>	(F)

Condição de Parada (Linha 24): Não satisfeita. O loop continua, pois Aprendizagem, Sala de aula, Aluno não possuem ambas as marcas.

5.1.2 Iteração 2

Execução de buscaRelações(E, G)

O novo conjunto E é $E_{original} \cup G_{I1}$, e o novo G é G_{I1} . Novas relações são procuradas entre os entes gerados (G) e os entes originais (E). Três novos entes (leg_5 a leg_7) são gerados.

Tabela 4 – Resultados da função buscaRelações na Iteração 2 (Exemplos)

Par (g_i, e_i)	Relação Encontrada	Novos Entes Gerados (leg_i)
(Transmitir, Aluno)	Requisito	$leg_5 = Participao$
(Ensinar, Sala de aula)	Meio	$leg_6 = Recursos$
(Adquirido, Aprendizagem)	Processo	$leg_7 = Absoro$

Estado Final dos Conjuntos (Iteração 2)

Tabela 5 – Estado Final dos Conjuntos (Iteração 2)

Conjunto	Conteúdo (Abreviado)	Card.
E	$\{P, C, Ap, Sala, Al, T, E, Ad, Amb\}$	$ E = 9$
G	$\{Participao, Recursos, Absoro\}$	$ G = 3$
L	$L_{I1} \cup \{(T, Al, \{Part\}), (E, Sala, \{Rec\}), \dots\}$	$ L = 7$
A	$A_{I1} \cup \{(Al, Part), (Part, T), \dots\}$	$ A = 14$

Tabela 6 – Estado de Marcas Propagadas em E (Iteração 2)

Elemento	Marcas (C=Ceiling, F=Floor)
<i>Professor</i>	(C, F)
<i>Conhecimento</i>	(C, F)
<i>Aprendizagem</i>	(C, F)
<i>Aluno</i>	(C, F)
<i>Saladeaula</i>	(C)

Condição de Parada (Linha 24): Não satisfeita. O elemento Sala de aula ainda não possui a marca `LinkedToFloor`, portanto, mais iterações são necessárias.

5.2 Exemplo de Iteração 2

Os conjuntos iniciais para a simulação são definidos como:

- C (Ceiling): $\{Diabetes\}$
- F (Floor): $\{Consumodeacar\}$
- R (Relevant Elements): $\{Exercicio, Dietabalaneada\}$

Conjuntos após a Inicialização (Linhas 4-7):

- $E = C \cup F \cup R$: $\{Diabetes, Consumodeacar, Exercicio, Dietabalaneada\}$

- $G \leftarrow E: \{Diabetes, Consumodeacar, Exercio, Dietabalaneada\}$
- $L \leftarrow \emptyset$ (Lista de Relações)
- $A \leftarrow \emptyset$ (Arestas/Relações de Entes Gerados)

Marcas Iniciais (Linhas 8-13):

- *Diabetes* é marcado como `LinkedToCeiling`. (C)
- *Consumodeacar* é marcado como `LinkedToFloor`. (F)

5.2.1 Iteração 1

Execução de buscaRelações(E, G)

Na Iteração 1, pares de elementos de E (o conjunto inicial) são enviados para a IA. O *Human-in-the-loop* (HITL) gera novos entes (leg_1 a leg_3) a partir de relações encontradas.

Tabela 7 – Resultados da função buscaRelações na Iteração 1 (Exemplos)

Par (g_i, e_i)	Relação Encontrada	Novos Entes Gerados (leg_i)
(<i>Diab</i> , <i>Cons</i>)	Causa/Efeito	$leg_1 = Glicemia$
(<i>Diab</i> , <i>Exer</i>)	Prevenção/Tratamento	$leg_2 = Metabolismo$
(<i>Cons</i> , <i>Dieta</i>)	Componente	$leg_3 = Nutrientes$

Estado Final dos Conjuntos (Iteração 1):

Tabela 8 – Estado Final dos Conjuntos (Iteração 1)

Conjunto	Conteúdo (Abreviado)	Card.
E	$\{Diab, Cons, Exer, Dieta\}$	$ E = 4$
G	$\{Glicemia, Metabolismo, Nutrientes\}$	$ G = 3$
L	$\{(Diab, Cons, \{Glicemia\}), (Diab, Exer, \{Metab\}), (Cons, Dieta, \{Nutr\})\}$	
A	$\{(Cons, Glic), (Glic, Diab), (Exer, Metab), (Metab, Diab), (Dieta, Nutr), (Nutr, Dieta)\}$	

Propagação de Marcas (I1):

- *Consumodeacar*(F) está ligado a *Glicemia*. → *Glicemia* recebe (F).
- *Diabetes*(C) está ligado a *Glicemia*. → *Glicemia* recebe (C).
- *Consumodeacar*(F) está ligado a *Nutrientes*. → *Nutrientes* recebe (F).
- *Dietabalaneada* está ligada a *Nutrientes*(F). → *Dietabalaneada* recebe (F).
- *Exercio* está ligado a *Metabolismo*(C). → *Exercio* recebe (C).

- $Diab(C)$ está ligado a *Metabolismo*. $\rightarrow$ *Metabolismo* recebe (C).

Tabela 9 – Estado de Marcas Propagadas em E (Iteração 1)

Elemento	Marcas (C=Ceiling, F=Floor)
<i>Diabetes</i>	(C)
<i>Consumodeacar</i>	(C, F)
<i>Exercicio</i>	(C)
<i>Dietabalaneada</i>	(F)

Condição de Parada (Linha 24): Não satisfeita. *Diabetes*, *Exercicio*, e *Dietabalaneada* não possuem ambas as marcas. O loop continua.

5.2.2 Iteração 2

Execução de buscaRelações(E, G)

O novo conjunto E é $E_{I1} \cup G_{I1}$ (7 elementos), e o novo G é G_{I1} (3 elementos).

Tabela 10 – Resultados da função buscaRelações na Iteração 2 (Estratégico)

Par (g_i, e_i)	Relação Encontrada	Novos Entes Gerados (leg_i)
(<i>Metab, Cons</i>)	Impacto	$leg_4 = Energia$
(<i>Glic, Dieta</i>)	Controle	$leg_5 = Restrio$
(<i>Nutr, Diab</i>)	Efeito	$leg_6 = Sade$

1. ($Nutrientes(F) \leftrightarrow Diabetes(C)$): *Nutrientes* tem (F). $\rightarrow$ *Diabetes* recebe (F). (✓ *Diab* Completo)
2. ($Glicemia(C, F) \leftrightarrow Dietabalaneada(F)$): *Glicemia* tem (C). $\rightarrow$ *Dietabalaneada* recebe (C). (✓ *Dieta* Completo)
3. ($Metabolismo(C) \leftrightarrow Consumodeacar(C, F)$): *Metabolismo* tem (C). $\rightarrow$ *Metabolismo* recebe (F) via *Cons*.
4. ($Metabolismo(C, F) \leftrightarrow Exercicio(C)$): *Metabolismo* tem (F). $\rightarrow$ *Exercicio* recebe (F). (✓ *Exer* Completo)

Estado Final dos Conjuntos (Iteração 2)

Tabela 11 – Estado Final dos Conjuntos (Iteração 2)

Conjunto	Conteúdo (Abreviado)	Card.
E	$\{Diab, Cons, Exer, Dieta, Glic, Metab, Nutr\}$	$ E = 7$
G	$\{Energia, Restrio, Sade\}$	$ G = 3$
L	$L_{I1} \cup \{(Metab, Cons, \{leg_4\}), (Glic, Dieta, \{leg_5\}), (Nutr, Diab, \{leg_6\})\}$	$ L = 6$
A	$A_{I1} \cup \{(Cons, Enrg), (Enrg, Metab), (Dieta, Rest), (Rest, Glic), (Diab, Sade), (Sade, Exer)\}$	$ A = 12$

Tabela 12 – Estado de Marcas Propagadas em E (Iteração 2)

Elemento	Marcas (C=Ceiling, F=Floor)
<i>Diabetes</i>	(C, F)
<i>Consumodeacar</i>	(C, F)
<i>Exercicio</i>	(C, F)
<i>Dietabalaneada</i>	(C, F)

Condição de Parada (Linha 24): Satisfeita. Todos os elementos $e \in E$ (os 4 elementos originais) são `LinkedToCeiling` e `LinkedToFloor`. O loop externo pode ser encerrado.

5.3 Conclusão Geral

Os resultados demonstraram que o método CAPTO2, com aprimoramentos para trabalhar em conjunto com modelos de IA Generativa, valida sua aplicabilidade prática em contextos onde é necessário mapear problemas complexos e construir bases de dados relevantes. A abordagem *Middle-out* se mostrou eficaz para iniciar a investigação do domínio a partir de elementos centrais, expandindo-se tanto para conceitos mais genéricos (generalização) quanto para os mais específicos (especificação), sem a necessidade de um ponto de partida pré-definido como os métodos *Top-down* e *Bottom-up*. A intervenção humana (*Human-in-the-Loop*) na validação das relações geradas pela IA se mostrou crucial, garantindo a acurácia e a contextualização do conhecimento capturado, um desafio comum para modelos de linguagem em domínios especializados.

A utilização de fundamentos filosóficos como a Análise Ontológica Fundamental (AOF) forneceu uma base sólida e regras claras para a identificação de relações ontológicas básicas, tornando o processo de conceitualização menos subjetivo e mais estruturado. Isso é particularmente importante em projetos de ciência de dados, onde a fase inicial de entendimento do domínio e seleção de atributos é fundamental para o sucesso do projeto.

O exemplo didático da seção 3.5 ilustrou como o método pode ser aplicado para transformar um texto descritivo em um modelo conceitual, utilizando as métricas propostas para guiar o processo de captura. A análise das métricas, como densidade e produtividade, permitiu avaliar a qualidade e a eficiência do modelo obtido, além de fornecer um critério para decidir se o processo de investigação deve continuar ou ser interrompido.

A principal contribuição deste trabalho é a proposta do método CAPTO2, que integra a eficiência da IA Generativa com a intervenção e o conhecimento de domínio de um especialista humano. O método oferece um framework para a captura de conhecimento tácito, que muitas vezes é negligenciado, e o transforma em um modelo conceitual explícito.

A pesquisa também contribuiu com a definição de métricas claras (Número de Iterações, Raio da Esfera, Densidade, Eficiência e Produtividade) para avaliar o processo de captura de ontologias, permitindo comparações e análises entre diferentes processos de modelagem de

domínios.

REFERÊNCIAS

BAI, T. et al. A method for exploring implicit concept relatedness in biomedical knowledge network. **BMC Bioinformatics**, v. 17, 2016. Disponível em: <<https://doi.org/10.1186/s12859-016-1131-5>><https://doi.org/10.1186/s12859-016-1131-5>.

BOMMASANI, R. e. a. On the opportunities and risks of foundation models. **arXiv:2409.04267v1 [cs.AI]**, 2021. Disponível em: <<https://arxiv.org/abs/2108.07258>><https://arxiv.org/abs/2108.07258>.

BRADY, S. et al. Development of conceptual models to guide public health research, practice, and policy: Synthesizing traditional and contemporary paradigms. **Health Promotion Practice**, v. 21, n. 4, p. 510–524, 2020.

BUDD, S.; ROBINSON, E. C.; KAINZ, B. A survey on active learning and human-in-the-loop deep learning for medical image analysis. **Medical Image Analysis**, v. 71, p. 102062, 2021. ISSN 1361-8415. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S1361841521001080>><https://www.sciencedirect.com/science/article/pii/S1361841521001080>.

CHEN, H. e. a. An overview of domain-specific foundation model: Key technologies, applications and challenges. **arXiv:2409.04267**, 2024. Disponível em: <<https://arxiv.org/abs/2409.04267>><https://arxiv.org/abs/2409.04267>.

FAYYAD, U.; PIATETSKY-SHAPIO, G.; SMYTH, P. The kdd process for extracting useful knowledge from volumes of data. **Commun. ACM**, Association for Computing Machinery, New York, NY, USA, v. 39, n. 11, p. 27–34, nov. 1996. ISSN 0001-0782. Disponível em: <<https://doi.org/10.1145/240455.240464>><https://doi.org/10.1145/240455.240464>.

GRUBER, T. R. A translation approach to portable ontology specifications. **Knowledge Acquisition**, v. 5, n. 2, p. 199–220, 1993. ISSN 1042-8143. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S1042814383710083>><https://www.sciencedirect.com/science/article/pii/S1042814383710083>.

GU, Y. e. a. Domain-specific language model pretraining for biomedical natural language processing. **ACM Transactions on Computing for Healthcare**, 2024. Disponível em: <<https://dl.acm.org/doi/10.1145/3458754>><https://dl.acm.org/doi/10.1145/3458754>.

GUYON, I. et al. Analysis of the automl challenge series 2015–2018. In: _____. **Automated Machine Learning: Methods, Systems, Challenges**. Cham: Springer International Publishing, 2019. p. 177–219. ISBN 978-3-030-05318-5. Disponível em: <https://doi.org/10.1007/978-3-030-05318-5_10>https://doi.org/10.1007/978-3-030-05318-5_10.

JAIN, N.; SHARMA, L. An ontology based on the methodology proposed by ushold and king. **International Journal of Synthetic Emotions (IJSE)**, v. 7, n. 1, p. 13–26, 2016.

MARTINEZ, I.; VILES, E.; G. Olaizola, I. Data science methodologies: Current challenges and future approaches. **Big Data Research**, v. 24, p. 100183, 2021. ISSN 2214-5796. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2214579620300514>><https://www.sciencedirect.com/science/article/pii/S2214579620300514>.

- MEMARIAN, B.; DOLECK, T. Human-in-the-loop in artificial intelligence in education: A review and entity-relationship (er) analysis. **Computers in Human Behavior: Artificial Humans**, v. 2, n. 1, p. 100053, 2024. ISSN 2949-8821. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2949882124000136>><https://www.sciencedirect.com/science/article/pii/S2949882124000136>.
- NONAKA, I. The knowledge creating company. **Harvard Business Review**, v. 69, p. 96–104, 1991.
- SU, X. et al. Kgarevion: An ai agent for knowledge-intensive biomedical qa. **arXiv:2410.04660 [cs.AI]**, 2024. Disponível em: <<https://doi.org/10.48550/arXiv.2410.04660>><https://doi.org/10.48550/arXiv.2410.04660>.
- WANG, J.; GUO, B.; CHEN, L. **Human-in-the-loop Machine Learning: A Macro-Micro Perspective**. 2022. Disponível em: <<https://arxiv.org/abs/2202.10564>><https://arxiv.org/abs/2202.10564>.
- WU, X. et al. A survey of human-in-the-loop for machine learning. **Future Generation Computer Systems**, v. 135, p. 364–381, 2022. ISSN 0167-739X. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0167739X22001790>><https://www.sciencedirect.com/science/article/pii/S0167739X22001790>.
- YUAN, J. et al. Constructing biomedical domain-specific knowledge graph with minimum supervision. **Knowledge and Information Systems**, v. 62, p. 317–336, 2020. Disponível em: <<https://doi.org/10.1007/s10115-019-01351-4>><https://doi.org/10.1007/s10115-019-01351-4>.